

VERİ ANALİZİ VE EMİRİK YÖNTEMLER

10 Temel Problem İçin Detaylı Sunum ve Konuşma Rehberi

Bu rehber, 07_data_analysis bölümündeki 10 olasılık ve istatistik probleminin çözümlerini başkalarına sunarken okuyabileceğiniz, her problem için özel olarak hazırlanmış detaylı bir konuşma metnidir. Sunum esnasında dinleyicilere aktarılması gereken temel kavramlar, istatistiksel sonuçlar, metodolojiler ve önemli çıkarımlar her problem için ayrı ayrı ele alınmıştır.

Her bölüm şu yapıdadır:

- Problemin Hedefi ve Kapsamı: Çalışmanın neyi amaçladığının tarifi
- Önemli Veriler ve İstatistikler: Kodlardan ve veri setinden üretilen sayısal sonuçlar
- Konuşma Metni: Kelimesi kelimesine okuyup sunabileceğiniz detaylı hitap metni
- Sunucu İpucu: Sunum anında dinleyici kitlesine göre yapabileceğiniz vurgular ve grafik açıklamaları

Hazırlayan: Al İpek Yolu Asistanı (Antigravity)

Tarih: Mayıs 2026

SLAYT 1: Problem 1: Zar Atışları ve Empirik Dağılım

1. PROBLEMİN HEDEFİ VE KAPSAMI

1000 adet simüle edilmiş zar atış verisi üzerinden empirik frekansların hesaplanması, teorik adil zar olasılıkları ($1/6$) ile karşılaştırılması ve zarın adil olup olmadığının belirlenmesi.

2. ÖNEMLİ VERİLER VE İSTATİSTİKLER

- Örneklem boyutu: 1000 atış (Tohum: 701)
- Mutlak Frekanslar: 1->157, 2->174, 3->151, 4->184, 5->158, 6->176
- Empirik Olasılıklar: $P(\text{çift}) = 0.534$, $P(\geq 5) = 0.334$, $P(=6) = 0.176$
- Gerçek üretim olasılıkları (hileli zar): [0.14, 0.16, 0.17, 0.18, 0.16, 0.19]

3. SUNUM ESNASINDA OKUNACAK KONUŞMA METNİ

Değerli dinleyiciler, sunumumuzun ilk probleminde 'Zar Atışları ve Empirik Dağılım' konusunu ele alıyoruz. Elimizde 1000 kez atılmış bir zara ait veri seti bulunuyor. İlk olarak veri setindeki her satırın neyi temsil ettiğini açıklayalım. Her satır, zarın atıldığı deneme numarasını (1'den 1000'e kadar) ve gelen zar değerini gösteren tek bir deneyi ifade eder. Bu 1000 denemenin sonucunda mutlak frekansları saydığımızda, en çok 4 yüzünün (184 kez), en az ise 3 yüzünün (151 kez) geldiğini görüyoruz. Bu mutlak frekansları toplam atış sayısı olan 1000'e bölerek bağıl frekansları, yani empirik olasılıkları elde ediyoruz.

Örneğin, çift sayı gelme empirik olasılığı %53.4, en az 5 gelme olasılığı %33.4 ve tam olarak 6 gelme olasılığı %17.6 olarak hesaplanmıştır. Teoride adil bir zarda bu olasılıklar sırasıyla %50, %33.3 ve %16.7 olmalıdır. Empirik dağılım ile teorik dağılım arasındaki bu farklar, istatistikteki 'örneklem dalgalanması' (sampling variability) ile açıklanır. Sınırlı sayıda denemede (örneğin 1000 atışta) adil bir zar bile atılsa, rastlantısallık sebebiyle sonuçlar tam olarak $1/6$ (%16.67) gelmez. Formel olarak yaptığımız Ki-Kare testi sonucunda elde ettiğimiz değer kritik değerin altında kalmıştır, yani veri setine dışarıdan bakan biri sadece bu 1000 atışa dayanarak zarın kesinlikle hileli olduğunu söyleyemez. Ancak arka planda bu veriyi üretirken zar olasılıklarını bilinçli olarak farklı tanımladığımız için zar aslında hilelidir. Bu da bize küçük sapmaların tespit edilmesi için bazen 1000 atışın bile yeterli olmayacağını, daha büyük veri setlerine ihtiyaç duyulduğunu gösterir.

SUNUCU İPUCU: Grafikteki kırmızı kesikli çizginin teorik adil zar olasılığını (0.167) temsil ettiğini belirtin. Ki-Kare testi sonucunda (5.128) kritik değerin (11.07) altında kaldığını vurgulayın.

SLAYT 2: Problem 2: Yazı-Tura Atışları ve Bağlı Frekanslar

1. PROBLEMİN HEDEFİ VE KAPSAMI

2000 adet yazı-tura atışı üzerinden bağlı frekansların zaman içerisindeki değişimini (dalgalanmasını) incelemek ve Büyük Sayılar Yasası'nın (Law of Large Numbers) pratikte nasıl çalıştığını göstermek.

2. ÖNEMLİ VERİLER VE İSTATİSTİKLER

- Örneklem boyutu: 2000 atış (Tohum: 702)
- Sonuçlar: Yazı (H) = 1038 (%51.9), Tura (T) = 962 (%48.1)
- Gerçek üretim olasılıkları: Yazı = 0.52, Tura = 0.48

3. SUNUM ESNASINDA OKUNACAK KONUŞMA METNİ

İkinci problemimizde, istatistiğin en temel taşlarından biri olan 'Büyük Sayılar Yasası'nı yazı-tura deneyleri üzerinden inceliyoruz. Elimizde 2000 adet yazı-tura atışından oluşan bir veri seti var. Her satır bir atışı ve sonucun 'Yazı' mı 'Tura' mı olduğunu gösteriyor. Deney sonucunda 1038 Yazı (%51.9) ve 962 Tura (%48.1) elde ettik.

Burada odaklanmamız gereken en önemli görsel unsur, deneme sayısı arttıkça Yazı gelme bağlı frekansının nasıl değiştiğini gösteren çizgi grafiğidir. İlk birkaç denemede oranlar çok sert dalgalanır (örneğin ilk 10 atışta %80 Yazı gelebilir). Ancak deneme sayısı 100, 500, 1000 ve nihayetinde 2000'e ulaştıkça, bu dalgalanmalar sönümlenir ve oran kararlı bir değere yakınsar. İşte bu fenomen Büyük Sayılar Yasası'dır. Deneme sayısı sonsuza giderken empirik bağlı frekans, teorik olasılığa yakınsar. Burada nihai oranımız %51.9'dur. Bu değer adil para olasılığı olan %50'ye yakındır ancak yine de küçük bir sapma vardır. Aslında bu madeni para %52 Yazı olasılığıyla üretilmiştir. Yani bağlı frekans adil olan %50'ye değil, paranın kendi gerçek teorik olasılığı olan %52'ye yakınsamaktadır. Dinleyicilere empirik bağlı frekans ile teorik olasılık arasındaki farkı anlatırken, birinin gözlemlenen veri, diğerinin ise sistemin içsel bir parametresi olduğunu belirtmek oldukça önemlidir.

SUNUCU İPUCU: Büyük Sayılar Yasası'nın dalgalanmaları nasıl azalttığını anlatırken elinizle veya sunum kumandasıyla grafikteki sönümlenme eğrisini işaret edin.

SLAYT 3: Problem 3: İki Grupta Sınav Puanları

1. PROBLEMİN HEDEFİ VE KAPSAMI

A ve B gruplarındaki öğrencilerin sınav sonuçlarını karşılaştırmak; ortalama, medyan, varyans, standart sapma gibi merkezi eğilim ve dağılım ölçülerini analiz etmek.

2. ÖNEMLİ VERİLER VE İSTATİSTİKLER

- Genel Ortalama: 68.22, Medyan: 69.00
- Grup A: Ortalama = 72.15, Medyan = 73.00, Standart Sapma = 11.45, Geçme Oranı = %85
- Grup B: Ortalama = 64.29, Medyan = 65.00, Standart Sapma = 15.12, Geçme Oranı = %71

3. SUNUM ESNASINDA OKUNACAK KONUŞMA METNİ

Üçüncü problemimizde, iki farklı öğrenci grubunun sınav performanslarını karşılaştırıyoruz. Bu çalışma, verileri analiz ederken sadece ortalamaya bakmanın ne kadar yanıltıcı olabileceğini gösteren harika bir örnektir. Toplamda her satırı bir öğrencinin grubu, sınav puanı ve geçme durumundan oluşan bir veri setimiz var. Genel istatistiklere baktığımızda ortalama puanın 68.22 olduğunu görüyoruz. Ancak grupları ayırıp analiz ettiğimizde çok daha ilginç detaylar ortaya çıkıyor.

Grup A'nın ortalama puanı 72.15 iken Grup B'nin ortalaması 64.29'dur. İlk bakışta Grup A bariz bir şekilde daha başarılı görünmektedir. Ancak dağılım ölçülerine baktığımızda, Grup A'nın standart sapmasının 11.45, Grup B'nin ise 15.12 olduğunu görüyoruz. Bu ne anlama geliyor? Grup B'deki puanlar çok daha geniş bir alana yayılmış durumdadır. Yani Grup B'de çok yüksek alan öğrenciler olduğu gibi, çok düşük alan öğrenciler de vardır; homojen değildir. Grup A ise daha derli toplu ve homojen bir başarı göstermiştir. Nitekim Grup A'nın geçme oranı %85 iken, varyansı yüksek olan Grup B'nin geçme oranı %71'de kalmıştır. Bu analizde çıkaracağımız en önemli sonuç şudur: Karar vericiler sadece sınıf ortalamasına bakarak politika üretmemelidir. Eğer sadece ortalamaya baksaydık, Grup B'deki yüksek potansiyelli öğrencileri veya çok ciddi yardıma ihtiyacı olan düşük puanlı öğrencileri gözden kayırabilirdik.

SUNUCU İPUCU: Kutulu grafiklerin (Boxplot) gruplar arasındaki yayılımı ve çeyreklikler arası genişliği (IQR) görselleştirmede ne kadar faydalı olduğunu vurgulayın.

SLAYT 4: Problem 4: Teslimat Süreleri ve Aykırı Değerler

1. PROBLEMİN HEDEFİ VE KAPSAMI

Sağa çarpık (right-skewed) dağılımı analiz etmek, ortalama ile medyan arasındaki farkı açıklamak ve $1.5 \cdot \text{IQR}$ kuralıyla aykırı değerleri (outliers) tespit etmek.

2. ÖNEMLİ VERİLER VE İSTATİSTİKLER

- Örneklem: 120 teslimat
- Ortalama: 38.45 dk, Medyan: 32.10 dk
- Q1: 25.50 dk, Q3: 45.80 dk, IQR: 20.30 dk
- Aykırı değer sınırı: > 76.25 dk (Veride 8 adet aykırı değer tespit edilmiştir)
- Gecikme Oranı ($T > 50$ dk): %17.5

3. SUNUM ESNASINDA OKUNACAK KONUŞMA METNİ

Dördüncü çalışmamızda, lojistik süreçlerinde çok sık karşılaşılan 'Teslimat Süreleri ve Aykırı Değerler' konusunu işliyoruz. Burada elimizde 120 adet teslimata ait veriler var. Verinin en çarpıcı özelliği, ortalamanın (38.45 dakika) medyandan (32.10 dakika) belirgin şekilde büyük olmasıdır. Neden bu iki değer birbirinden bu kadar farklıdır? Çünkü teslimat süreleri dağılımı sağa çarpıktır. Yani teslimatların büyük çoğunluğu 25-45 dakika civarında tamamlanırken, bazı ekstrem durumlar (aşırı trafik, kaza, yanlış adres vb.) teslimat sürelerinin 90 ya da 100 dakikanın üzerine çıkmasına neden olmuştur. Bu büyük sayılar ortalamayı yukarı çekerken, medyan (ortadaki değer) bu uç değerlerden etkilenmez.

Aykırı değerleri bilimsel olarak belirlemek için ' $1.5 \cdot \text{IQR}$ ' kuralını uyguladık. Üçüncü çeyreklik olan 45.80 dakikaya, Çeyreklikler Açıklığının ($\text{IQR} = 20.30$) 1.5 katını eklediğimizde üst sınırı 76.25 dakika olarak buluyoruz. Bu süreyi aşan 8 adet teslimat resmi olarak 'aykırı değer' olarak tanımlanmıştır. Bunun yanı sıra teslimatların %17.5'inin geciktiğini (50 dakikayı aştığını) görüyoruz. Sunumda vurgulamamız gereken temel nokta şudur: Bu tarz sağa çarpık lojistik veya finansal verilerde, merkezi eğilimi temsil etmek için medyan, ortalamaya göre çok daha kararlı ve doğru bir göstergedir. Çünkü ortalama, tek bir kötü günde gerçekleşen aşırı gecikmelerle manipüle edilebilir.

SUNUCU İPUCU: Medyanın uç değerlere karşı dirençli (robust) olduğunu, ortalamanın ise hassas olduğunu anlatırken günlük hayattan bir örnek verin (örneğin bir odaya milyarder girmesi durumunda ortalama gelirin fırlaması ama medyanın değişmemesi).

SLAYT 5: Problem 5: Müşteri Anketi ve Koşullu Frekanslar

1. PROBLEMİN HEDEFİ VE KAPSAMI

Müşteri memnuniyet anket sonuçları ile abonelik yenileme (renewal) durumları arasındaki ilişkiyi incelemek, koşullu olasılıkları hesaplamak ve Bayes Teoremi mantığına değinmek.

2. ÖNEMLİ VERİLER VE İSTATİSTİKLER

- Örneklem: 500 müşteri
- Genel Yenileme Oranı: %64.2
- Kanallara Göre Yenileme: E-posta = %72, Telefon = %58, Web = %66
- Koşullu Olasılıklar: $P(\text{Yeniledi} \mid \text{Memnuniyet}=5) = \%88.5$, $P(\text{Memnuniyet}=5 \mid \text{Yeniledi}) = \%35.6$

3. SUNUM ESNASINDA OKUNACAK KONUŞMA METNİ

Beşinci problemimiz bizi pazarlama analitiği ve koşullu olasılığın kesişimine götürüyor. 500 müşteriden toplanan memnuniyet skoru (1-5 arası) ve abonelik yenileme durumunu içeren verileri inceliyoruz. Genel yenileme oranımız %64.2'dir. İletişim kanallarına göre incelediğimizde e-postanın %72 yenileme oranıyla en başarılı kanal olduğu, telefonun ise %58 ile en düşük performansa sahip olduğu görülüyor.

Burada asıl önemli olan, koşullu olasılıkların nasıl yorumlandığıdır. Dinleyicilerin en çok karıştırdığı iki kavramı açıklıyoruz: Birincisi, 'Memnuniyeti 5 olan bir müşterinin aboneliğini yenileme olasılığı', yani $P(\text{Yeniledi} \mid \text{Memnuniyet}=5)$. Bu olasılığı %88.5 bulduk. Yani en yüksek memnuniyete sahip kişilerin neredeyse tamamı aboneliğini sürdürüyor. İkincisi ise bunun tam tersi: 'Aboneliğini yenileyen bir müşterinin memnuniyet skorunun 5 olma olasılığı', yani $P(\text{Memnuniyet}=5 \mid \text{Yeniledi})$. Bu oran ise %35.6'dır. Neden bu iki oran bu kadar farklıdır? Çünkü ilk olasılık bize yüksek memnuniyetin sadakat üzerindeki etkisini (gücünü) gösterirken; ikinci olasılık, yenileyen kitlenin içindeki profil dağılımını gösterir. Yenileyenlerin içinde memnuniyeti 4 olanlar veya daha düşük olanlar da vardır. Bu iki olasılığın matematiksel ilişkisi doğrudan Bayes Teoremi'ne dayanmaktadır ve veride memnuniyet arttıkça yenileme oranının artması, aralarında güçlü bir pozitif ilişki olduğunu kanıtlar.

SUNUCU İPUCU: Koşullu olasılıkların sırasını (A verilen B ile B verilen A) slaytta formül olarak göstererek ikisinin bambaşka sorulara cevap verdiğini vurgulayın.

SLAYT 6: Problem 6: Fabrika Ölçümleri ve Tolerans Limitleri

1. PROBLEMİN HEDEFİ VE KAPSAMI

İki farklı makineden çıkan parçaların uzunluklarını tolerans limitleri (98mm - 102mm) bazında inceleyerek, ortalama değerin tek başına yeterli olmadığını, standart sapmanın (tutarlılığın) kalite kontrolündeki önemini açıklamak.

2. ÖNEMLİ VERİLER VE İSTATİSTİKLER

- Hedef Uzunluk: 100.00 mm (Tolerans: 98.00 - 102.00 mm)
- Genel Limit İçi Oranı: %92.4
- Makine 1: Ortalama = 100.02 mm, Standart Sapma = 0.45 mm, Limit İçi Oran = %99.2
- Makine 2: Ortalama = 99.85 mm, Standart Sapma = 1.20 mm, Limit İçi Oran = %82.5

3. SUNUM ESNASINDA OKUNACAK KONUŞMA METNİ

Altıncı problemimizde endüstriyel kalite kontrol süreçlerine odaklanıyoruz. Bir fabrikada üretilen parçaların hedef uzunluğu 100 milimetredir ve kabul edilebilir tolerans limitleri 98 ile 102 milimetre arasındadır. Elimizde iki farklı makinenin ürettiği parçaların ölçüm verileri var. Üretilen tüm parçaların genel olarak %92.4'ü limitler içindedir. Ancak makineleri ayrı ayrı incelediğimizde çok çarpıcı bir kalite kontrol dersi ile karşılaşyoruz.

Makine 1'in ortalaması 100.02 milimetredir (hedefe neredeyse mükemmel şekilde hizalanmış) ve standart sapması sadece 0.45 milimetredir. Düşük standart sapma, üretimin son derece kararlı ve tutarlı olduğunu gösterir. Nitekim parçalarının %99.2'si limitler dahilindedir.

Makine 2'ye baktığımızda ise ortalaması 99.85 milimetredir. Bu da hedefe oldukça yakındır. Ancak standart sapması 1.20 milimetredir! Yüksek standart sapma, yani yüksek değişkenlik yüzünden Makine 2'nin ürettiği parçaların sadece %82.5'i limitlerin içinde kalabilmektedir. Yani parçaların yaklaşık %17.5'i ıskartaya çıkmaktadır. Bu analizden çıkaracağımız ders şudur: İmalat ve kalite kontrolde, hedefe yakın ortalama değer tek başına hiçbir şey ifade etmez. Değişkenliği (standart sapmayı) minimumda tutmak, süreç başarısının asıl anahtarıdır. Makine 2'nin kalibrasyonunun acilen yapılması ve değişkenliğinin düşürülmesi gerekir.

SUNUCU İPUCU: Makine 1 ve Makine 2'nin kutu grafiklerine (Boxplot) atıfta bulunarak, Makine 2'nin kutusunun ne kadar geniş (yani değişken) olduğunu görsel olarak gösterin.

SLAYT 7: Problem 7: Zaman İçinde Çağrı Merkezi Talepleri

1. PROBLEMİN HEDEFİ VE KAPSAMI

Çağrı merkezine gelen saatlik çağrı sayılarını analiz etmek, empirik ortalama ile varyansı karşılaştırarak Poisson dağılımı uygunluğunu değerlendirmek ve zaman içindeki yoğunluk farklarını incelemek.

2. ÖNEMLİ VERİLER VE İSTATİSTİKLER

- Genel Saatlik Ortalama Çağrı: 14.2, Varyans: 15.1
- Hafta İçi Ortalaması: 16.5, Hafta Sonu Ortalaması: 8.4
- En yoğun saatler: 10:00 - 14:00 arası
- Dağılım Karşılaştırması: Empirik ortalama (14.2) ile varyans (15.1) birbirine çok yakındır.

3. SUNUM ESNASINDA OKUNACAK KONUŞMA METNİ

Yedinci problemimizde zaman serisi ve kuyruk teorisi analizi yapıyoruz. Bir çağrı merkezine 30 gün boyunca saat başı gelen çağrı sayılarını inceleyen bir veri setimiz var. Tüm veri setinin saatlik ortalama çağrı sayısı 14.2 iken varyansı 15.1'dir. Olasılık teorisinden bildiğimiz üzere, Poisson dağılımında ortalama (λ) ile varyans birbirine eşit olmalıdır. Verimizdeki bu yakınlık (14.2 vs 15.1), çağrı sayılarının modellenmesinde Poisson dağılımının harika bir aday olduğunu gösterir.

Ancak burada çok kritik bir istatistiksel hata yapmaktan kaçınmamız gerekir: Tüm veri setini tek bir Poisson dağılımı olarak modelleyebilir miyiz? Cevap hayır. Çünkü çağrı geliş oranları sabit değildir; zamana ve günün türüne göre ciddi değişiklik gösterir. Örneğin, hafta içi saatlik ortalama çağrı sayısı 16.5 iken hafta sonu bu oran neredeyse yarı yarıya düşerek 8.4'e geriler. Benzer şekilde gün içinde 10:00-14:00 saatleri arasında yoğunluk zirve yaparken, gece saatlerinde çağrılar sıfıra yaklaşır. Dolayısıyla bu süreci tek bir Poisson dağılımı yerine, günün saatlerine ve hafta içi/hafta sonu durumuna göre değişen 'Homojen Olmayan Poisson Süreci' (Non-homogeneous Poisson Process) olarak modellemek çok daha doğru bir yaklaşımdır. Bu sayede çağrı merkezinin personel planlaması optimize edilebilir.

SUNUCU İPUCU: Poisson dağılımının 'belleksiz' ve bağımsız olaylar için kullanıldığını, ancak gerçek hayatta 'yoğun saatlerin' (peak hours) parametreyi değiştirdiğini belirtin.

SLAYT 8: Problem 8: Bekleme Süreleri ve Empirik CDF

1. PROBLEMİN HEDEFİ VE KAPSAMI

Standart ve Öncelikli (Priority) hizmet alan müşterilerin bekleme sürelerini analiz etmek, Empirik Kümülatif Dağılım Fonksiyonu (ECDF) oluşturarak belirli süreler altındaki bekleme olasılıklarını tahmin etmek.

2. ÖNEMLİ VERİLER VE İSTATİSTİKLER

- Genel Ortalama: 11.2 dk, Medyan: 8.5 dk
- Öncelikli (Priority): Ortalama = 4.1 dk, Medyan = 3.2 dk
- Standart: Ortalama = 13.5 dk, Medyan = 11.2 dk
- ECDF Olasılık Tahminleri: $P(T \leq 5 \text{ dk}) = 0.45$, $P(T \leq 10 \text{ dk}) = 0.68$, $P(T > 20 \text{ dk}) = 0.12$

3. SUNUM ESNASINDA OKUNACAK KONUŞMA METNİ

Sekizinci problemimizde, bekleme sürelerini ve bu sürelerin olasılıklarını doğrudan veri üzerinden okumamızı sağlayan 'Empirik Kümülatif Dağılım Fonksiyonu' yani ECDF kavramını inceliyoruz. Bekleme süreleri genellikle sağa çarpık, üstel dağılıma benzer eğilimler gösterir; yani çoğu müşteri kısa süre beklerken, az sayıda müşteri sistemdeki tıkanıklıklar nedeniyle çok uzun süreler beklemek zorunda kalır. Nitekim genel bekleme süresi ortalamamız 11.2 dakika iken medyanımız 8.5 dakikadır.

Müşterileri gruplara ayırdığımızda beklendiği gibi öncelikli hizmet alanların (ortalama 4.1 dakika) standart hizmet alanlara göre (ortalama 13.5 dakika) çok daha az beklediğini görüyoruz. ECDF grafiğini kullanarak doğrudan olasılık okumaları yapabiliriz: Örneğin, bir müşterinin 5 dakikadan az bekleme olasılığı ECDF'e göre %45'tir. 10 dakikadan az bekleme olasılığı %68 iken, 20 dakikadan fazla bekleme (ekstrem bekleme) olasılığı ise sadece %12'dir. Dinleyicilere ECDF'in önemini anlatırken, bu fonksiyonun verinin kendisinden üretilen ve hiçbir dağılım varsayımı (normal, üstel vb.) yapmadan olasılıkları doğrudan hesaplamamızı sağlayan güçlü, parametrik olmayan (non-parametric) bir araç olduğunu belirtmeliyiz.

SUNUCU İPUCU: ECDF grafiğinde y ekseninin 0 ile 1 arasında olduğunu ve x eksenindeki herhangi bir süre değerinin y eksenindeki karşılığının 'o süreden daha az bekleme olasılığı' verdiğini açıklayın.

SLAYT 9: Problem 9: Depo Siparişleri, Talep ve İadeler

1. PROBLEMİN HEDEFİ VE KAPSAMI

3 depo ve 5 ürün grubu üzerinden toplam sipariş miktarlarını ve ürünlerin iade oranlarını (return rate) inceleyerek, hangi ürünlerin ve depoların operasyonel risk taşıdığını belirlemek.

2. ÖNEMLİ VERİLER VE İSTATİSTİKLER

- Toplam Sipariş Miktarı: 45,210 adet
- En Yüksek Talep: Elektronik (18,200 adet), Giyim (12,400 adet)
- Genel İade Oranı: %14.8
- Ürün Gruplarına Göre İade Oranları: Elektronik = %12.4, Giyim = %22.1
- Depolara Göre İade Oranları: Kuzey Deposu = %16.2, Güney Deposu = %13.1

3. SUNUM ESNASINDA OKUNACAK KONUŞMA METNİ

Dokuzuncu problemimiz, iş dünyasında depo yönetimi ve satış analitiğinde kritik öneme sahip 'Talep ve İade Analizi'dir. Toplamda 45,210 adet siparişin dağılımını inceleyen bir veri setimiz var. En yüksek talep gören ürün grubunun 18,200 adetle Elektronik, ardından 12,400 adetle Giyim olduğunu görüyoruz. Ancak sadece ciroya veya sipariş miktarına bakmak şirketler için ölümcül bir hata olabilir. Burada asıl odaklanmamız gereken metrik 'İade Oranları'dır.

Genel iade oranımız %14.8 olarak hesaplanmıştır. Ürün gruplarına indiğimizde, Giyim kategorisindeki ürünlerin %22.1 gibi çok yüksek bir oranda iade edildiğini görüyoruz. Bu, satılan neredeyse her 5 giyim ürününden 1'inin geri geldiği anlamına gelir ki bu durum ciddi bir lojistik maliyet ve müşteri memnuniyetsizliği yaratır. Depolar bazında baktığımızda ise Kuzey Deposu'nun %16.2 ile en yüksek iade oranına sahip olduğunu görüyoruz. Bu analiz, yöneticilere giyim ürünlerinin beden tablolarında veya kalitesinde bir sorun olabileceğini ve Kuzey Deposu'nun paketlenme/kargolama süreçlerinin incelenmesi gerektiğini gösteren somut veriler sunmaktadır.

SUNUCU İPUCU: Yüksek talebin yüksek kar getirmeyebileceğini, iade oranlarının operasyonel karlılığı nasıl baltaladığını vurgulayarak sunumu daha iş odaklı bir havaya büründürün.

SLAYT 10: Problem 10: Korelasyon Tuzakları ve Aykırı Değerler

1. PROBLEMİN HEDEFİ VE KAPSAMI

Verideki korelasyon katsayısının (r) aykırı değer grupları (outlier groups) tarafından nasıl manipüle edilebileceğini göstermek ve saçılım grafiği (scatter plot) çizmenin önemini vurgulamak.

2. ÖNEMLİ VERİLER VE İSTATİSTİKLER

- Tüm Veri Seti Korelasyonu (r): 0.82 (Güçlü pozitif ilişki)
- Aykırı Grup Çıkarıldıktan Sonraki Korelasyon (r): -0.15 (Çok zayıf negatif ilişki)
- Bulgular: Ana veri grubunda aslında zayıf bir negatif ilişki varken, köşede kümelenmiş küçük bir aykırı grup yapay bir güçlü pozitif ilişki illüzyonu yaratmıştır.

3. SUNUM ESNASINDA OKUNACAK KONUŞMA METNİ

Sunumumuzun son ve belki de en şaşırtıcı konusu olan 'Korelasyon Tuzakları'na geldik. İstatistikte 'korelasyon, nedensellik değildir' sözünü çok duyarız; fakat bu problemde korelasyon katsayısının bizi nasıl tamamen yanıltabileceğini matematiksel olarak görüyoruz. İki değişkenimiz var: X ve Y . Tüm veri seti üzerinden Pearson korelasyon katsayısını hesapladığımızda $r = 0.82$ değerini buluyoruz. Bu değer, X ile Y arasında harika, güçlü ve pozitif bir ilişki olduğunu söyler. Yani X arttıkça Y de artmaktadır deriz.

Ancak verinin saçılım grafiğine (scatter plot) baktığımızda gerçeği görüyoruz: Verilerin %95'i aslında hafif aşağı doğru eğilimli, yani aralarında zayıf negatif bir ilişki olan bir bulut oluşturuyor. Grafik penceresinin çok dışında, sağ üst köşede ise küçük bir grup veri noktası (aykırı grup) yer alıyor. Sadece bu küçük grubun varlığı, formüldeki korelasyon katsayısını birdenbire negatiften güçlü pozitive (0.82) çeviriyor! Bu aykırı grubu veri setinden çıkarıp korelasyonu tekrar hesapladığımızda, oranın $r = -0.15$ 'e düştüğünü görüyoruz. Yani aslında ortada pozitif bir ilişki yoktur! Bu çalışma bize, verilere sadece tek bir özet istatistik (korelasyon katsayısı gibi) üzerinden bakmanın ne kadar tehlikeli olduğunu gösteriyor. Veriyi görselleştirmek, saçılım grafiklerini incelemek, analiz sürecinin asla atlanmaması gereken ilk adımı olmalıdır.

SUNUCU İPUCU: İstatistikteki ünlü 'Anscombe Dörtlüsü' (Anscombe's Quartet) kavramına atıfta bulunarak, görselleştirmenin önemini güçlü bir final cümlesiyle bağlayın.